# TP3: Les arbres de décision

# Classification

## Objectifs

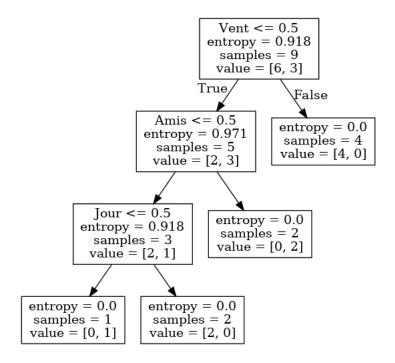
Dans ce TP, nous allons tout d'abord étudier l'algorithme des arbres de décision en classification.

### Un premier exemple

Ce code donne:

Dans cette partie nous allons voir un premier exemple sur la base de données barbecue vue en TD.

```
Etudiez le code suivant :
import pandas as pd
from sklearn import tree
def main():
    data = pd.read_csv("data/barbecue.csv")
    print(data)
    print(data['barbecue'])
    x_train = data
    y_train = data['barbecue']
    del x_train['barbecue']
    classifier = tree.DecisionTreeClassifier(criterion='entropy')
    classifier.fit(x_train, y_train)
    tree.export_graphviz(classifier, out_file='tree.dot',
                         feature_names=['Meteo', 'Amis', 'Vent', 'Jour'])
if __name__ == '__main__':
    main()
```



# La base glass

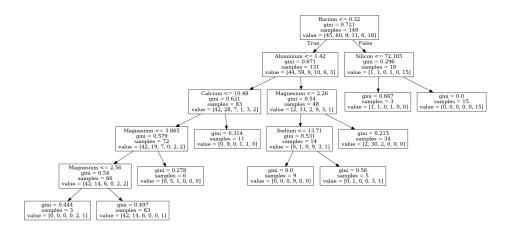
Nous allons travailler sur la base de données glass. Il s'agit d'apprendre le type d'un verre (batiment, voiture, ...) en fonction de différentes caractéristiques chimiques.

A partir du TP précédent et de l'exemple fourni précédemment, écrivez un modèle d'arbre de décision pour cette base de données. Attention à ne pas négliger la partie d'analyse des données.

#### Exemple de résultat attendu :

Train score: 0.7785234899328859, Test score 0.7076923076923077

[20		5	0	0	0	0]
	1	13	0	2	0	0]
	6	2	0	0	0	0]
	0	0	0	2	0	0]
	0	1	0	0	2	0]
Γ	2	0	0	0	0	911



# Regression

### Objectif

Les arbres de décision peuvent aussi être utilisés pour des problèmes de regression. Dans cette seconde partie, nous allons étudier la base de données winequality-red. Il s'agit de prédire la qualité d'un vin en fonction de différentes caractéristiques chimiques. La dernière colonne correspond à la qualité du vin, représentée par une note entière. Vous pouvez également vous amuser avec la base sur le vin blanc.

### A vous de jouer

Comme pour la première partie, récupérez la base, analysez les données, et effectuez un apprentissage avec les arbres de décision.

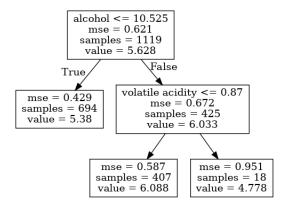
Vous devez utiliser les bibliothèques suivantes :

- from sklearn.tree import DecisionTreeRegressor
- from sklearn.model\_selection import train\_test\_split
- from sklearn.metrics import mean\_absolute\_error, mean\_squared\_error, r2\_score

Exemple de résultat attendu :

Coefficient of determination: 0.265941458484

MAE: 0.5815440506 MSE: 0.530038694448



# Résumé

- Les arbres de décision sont des algorithmes simples à mettre en place et faciles à comprendre.
- Ils souffrent toutefois d'un fort surapprentissage possible, il est donc important de limiter la taille des arbres.